



آزمون پایانی

راهنمای آزمون

۱. آزمون سه بخش دارد: مفهومی (۳۵ نمره)، محاسباتی (۳۵ نمره) و بررسی و اصلاح کد (۳۰ نمره).
۲. در پرسش‌های محاسباتی، مراحل حل نمره دارد؛ صرف نوشتن پاسخ نهایی کافی نیست. تا سه رقم اعشار گرد کنید.
۳. در پرسش‌های کد، هر باگ را «شماره‌گذاری، توضیح علت خطا، و نسخه اصلاح شده» بنویسید. یافتن باگ بدون توضیح، نیمی از نمره را دارد.
۴. استفاده از ماشین حساب ساده مجاز است. همه لگاریتم‌ها طبیعی ($\ln$) هستند مگر خلاف آن ذکر شود.

بخش اول — پرسش‌های مفهومی و سناریو محور (۳۵ نمره)

پرسش ۱

پرسپترون چندلایه: مقداردهی اولیه و پویایی گرادین

(۷ نمره)

سناریو

دانشجویی یک پرسپترون چندلایه (MLP) ده‌لایه برای دسته‌بندی می‌سازد. او همه وزن‌ها را برابر یک مقدار ثابت (نه لزوماً صفر) مقداردهی می‌کند، از فعال‌ساز sigmoid در تمام لایه‌ها استفاده می‌کند و با گرادین کاهش ساده (plain SGD) آموزش می‌دهد. پس از ده دوره، زیان آموزش تقریباً بدون تغییر مانده است.

الف) با استدلال ریاضی توضیح دهید چرا مقداردهی اولیه ثابت (یکسان برای همه نوروها) مانع از یادگیری می‌شود. چرا وجود بایاس متفاوت این مشکل را حل نمی‌کند؟ (۲ نمره)

ب) فرض کنید دانشجو وزن‌ها را تصادفی مقداردهی کند اما همچنان از sigmoid استفاده کند. با توجه به این که $\sigma'(x) \leq \frac{1}{4}$ ، به‌طور کمی توضیح دهید چرا در شبکه عمیق، گرادین لایه‌های ابتدایی محو می‌شود. یک کران بالا برای اندازه گرادین لایه اول بر حسب تعداد لایه‌ها بنویسید. (۲ نمره)

ج) دو راه حل مشخص برای رفع محوشدگی گرادین پیشنهاد دهید و سازوکار هر یک را توضیح دهید. (۲ نمره)

توجه

یکی از هم‌گروهی‌های او پیشنهاد می‌دهد: «کافی است نرخ یادگیری را ۱۰۰ برابر کنیم تا گرادین‌های کوچک جبران شوند.» آیا این راه حل درست است؟ در یک جمله دلیل رد یا تأیید آن را بنویسید. (۱ نمره)

پرسش ۲

شبکه پیچشی: هموردایی، ناوردایی و انتخاب‌های طراحی

(۷ نمره)

سناریو

تیمی یک شبکه عصبی پیچشی (CNN) برای دسته‌بندی تصویر طراحی می‌کند و بر سر چند تصمیم معماری بحث دارد.

الف) تفاوت «هموردایی نسبت به انتقال» (equivariance) و «ناوردایی نسبت به انتقال» (invariance) را دقیق بیان کنید. کدام عملگر کدام خاصیت را ایجاد می‌کند: لایه پیچش یا لایه ادغام (pooling)؟ (۲ نمره)

ب) یکی از اعضا می‌گوید «یک پیچش 5×5 بگذاریم»؛ دیگری می‌گوید «دو پیچش 3×3 پشت سر هم بهتر است». با محاسبه تعداد پارامتر و میدان گیرایی، بگویید کدام یک به صرفه‌تر است و چرا (فرض کنید تعداد کانال ورودی و خروجی برابر C است). (۲ نمره)

ج) نقش پیچش 1×1 چیست؟ به این ادعا پاسخ دهید: «پیچش 1×1 کار بی‌فایده‌ای است چون میدان گیرایی فضایی را تغییر نمی‌دهد.» (۱/۵ نمره)

د) پس از آموزش، مدل روی داده آموزش عالی اما روی یک تصویر تکی در زمان استنتاج بسیار بد عمل می‌کند. مظنون اصلی، لایه نرمال‌سازی دسته‌ای (BatchNorm) است. توضیح دهید در زمان استنتاج BatchNorm چه می‌کند و اگر فراخوانی `model.eval()` فراموش شود چه اتفاقی می‌افتد. (۱/۵ نمره)

پرسش ۳

شبکه‌های بازگشتی: محوشدگی، انفجار و دروازه‌ها

(۷ نمره)

سناریو

هنگام آموزش یک شبکه بازگشتی (RNN) ساده $\tanh$ روی دنباله‌های بلند، ابتدا زیان به‌طور ناگهانی به NaN می‌رسد؛ پس از افزودن یک ترفند، این مشکل رفع می‌شود اما حالا شبکه وابستگی‌های بلندمدت را یاد نمی‌گیرد.

الف) با نوشتن ژاکوبی بازگشتی $\frac{\partial h_t}{\partial h_{t-1}}$ ، توضیح دهید چرا در پس‌انتشار در زمان (BPTT) هم محوشدگی و هم انفجار گرادیان ممکن است رخ دهد. نقش شعاع طیفی ماتریس W_{hh} چیست؟ (۲/۵ نمره)

ب) کدام ترفند مشکل NaN (مرحله اول) را حل کرده است؟ چرا همان ترفند مشکل یادگیری بلندمدت (مرحله دوم) را حل نمی‌کند؟ (۱/۵ نمره)

ج) توضیح دهید سلول LSTM چگونه از طریق «حالت سلول» و «دروازه فراموشی» جریان گرادیان را حفظ می‌کند. (۲ نمره)

توجه

این جمله را ارزیابی کنید: «LSTM مشکل محوشدگی گرادیان را به‌طور کامل حذف می‌کند.» درست است یا نادرست؟ چرا؟ (۱ نمره)

پرسش ۴

مدل‌های مولد: خودرمگذار وردشی در برابر شبکه هم‌آورد

(۸ نمره)

دو مدل مولد روی یک مجموعه یکسان از تصاویر چهره آموزش داده می‌شوند: یک خودرمزگذارِ وردشی (VAE) و یک شبکه مولد هم‌آورد (GAN). نمونه‌های VAE مات و محو هستند؛ نمونه‌های GAN واضح اما کم‌تنوع‌اند و بسیاری شبیه هم.

الف) چرا نمونه‌های VAE مات می‌شوند؟ نقش فرض توزیع گاوسی/زیان بازسازی پیکسلی (MSE) را در این پدیده توضیح دهید. (۲ نمره)

ب) پدیده کم‌تنوعی GAN چه نام دارد و سازوکار آن چیست؟ چرا تابع زیان اصلی GAN می‌تواند این پدیده را تشدید کند؟ (۲ نمره)

ج) «ترفند بازپارامتری‌سازی» (reparameterization trick) را بنویسید و توضیح دهید چرا ضروری است. به این ادعا پاسخ دهید: «می‌توانستیم مستقیماً از $q(z|x)$ نمونه بگیریم و پس انتشار کنیم؛ ترفند لازم نیست.» (۲ نمره)

د) «فروپاشی پسین» (posterior collapse) در VAE چیست، چه زمانی رخ می‌دهد و یک راهکار کاهش آن را نام ببرید. (۲ نمره)

پرسش ۵

(۶ نمره)

ترنسفورمرها: مکانیزم توجه و اجزای معماری

الف) در توجه نقطه‌ای مقیاس‌شده، چرا امتیازها را بر $\sqrt{d_k}$ تقسیم می‌کنیم؟ به این پاسخ رایج و نادرست واکنش نشان دهید: «این تقسیم صرفاً برای نرمال‌سازی میانگین خروجی است.» (۲ نمره)

ب) چرا به «رمزگذاری موقعیت» (positional encoding) نیاز داریم؟ به این ادعا پاسخ دهید: «چون ترنسفورمر بازگشتی نیست، ترتیب توکن‌ها اهمیتی ندارد.» (۲ نمره)

ج) چرا از «توجه چندسر» (multi-head) به جای یک سر بزرگ استفاده می‌کنیم؟ آیا استفاده از h سر (هرکدام با بُعد $d_k = d_{\text{model}}/h$) تعداد پارامترها را نسبت به یک سر d_{model} -بُعدی افزایش می‌دهد؟ (۲ نمره)

بخش دوم — پرسش‌های محاسباتی (۳۵ نمره)

پرسش ۶

(۹ نمره)

عبور رفت و برگشت پرسپترون با softmax و آنتروپی متقاطع

یک شبکه کوچک با ورودی $x = [1, 2]^T$ ، یک لایه پنهان دو نورونی با فعال‌ساز ReLU، و یک لایه خروجی دو نورونی با softmax و زیان آنتروپی متقاطع در نظر بگیرید. وزن‌ها (بدون بایاس):

$$W^{(1)} = \begin{bmatrix} 0.1 & -0.2 \\ 0.3 & 0.4 \end{bmatrix}, \quad W^{(2)} = \begin{bmatrix} 0.5 & -0.3 \\ 0.2 & 0.6 \end{bmatrix}.$$

پیش‌فعال‌سازی لایه پنهان $z^{(1)} = W^{(1)}x$ و $h = \text{ReLU}(z^{(1)})$ است. لُجیت‌ها $o = W^{(2)}h$ و برچسب درست، کلاس نخست است: $y = [1, 0]^T$.

- الف) عبور رفت را کامل انجام دهید: $o, h, z^{(1)}$ ، بردار احتمال softmax و مقدار زیان L را حساب کنید. (۳ نمره)
- ب) عبور برگشت را انجام دهید: ابتدا $\frac{\partial L}{\partial o}$ ، سپس $\frac{\partial L}{\partial W^{(2)}}$ ، سپس $\frac{\partial L}{\partial h}$ ، $\frac{\partial L}{\partial z^{(1)}}$ و در نهایت $\frac{\partial L}{\partial W^{(1)}}$ را بیابید. (۴ نمره)

توجه

در این مسئله یک «مسیر مرده» وجود دارد. آن را بیابید و توضیح دهید چرا گرادین متناظر با یکی از نوروهای پنهان دقیقاً صفر می‌شود و این چه پیامدی برای به‌روزرسانی وزن‌ها دارد. (۲ نمره)

پرسش ۷

شبکه پیش‌بینی: ابعاد، تعداد پارامتر و میدان‌گیری

(۸ نمره)

سناریو

- معماری زیر روی ورودی $3 \times 224 \times 224$ (کانال $\times$ ارتفاع $\times$ عرض) اعمال می‌شود:
- Conv1: ۶۴ فیلتر 7×7 ، گام (stride) ۲، لایه‌گذاری (padding) ۳.
 - MaxPool: پنجره 3×3 ، گام ۲، لایه‌گذاری ۱.
 - Conv2: ۱۲۸ فیلتر 3×3 ، گام ۱، لایه‌گذاری ۱، اتساع (dilation) ۲.

الف) ابعاد فضایی خروجی هر سه لایه را (به‌همراه تعداد کانال) حساب کنید. (۲/۵ نمره)

ب) تعداد پارامترهای قابل‌یادگیری Conv1 و Conv2 را (با بایاس) بیابید. تعداد پارامتر لایه MaxPool چقدر است؟ (۲/۵ نمره)

ج) میدان‌گیری (receptive field) یک نورون در خروجی Conv2 نسبت به تصویر ورودی را حساب کنید. (۳ نمره)

توجه

دو دام رایج در این مسئله وجود دارد: (۱) اثر اتساع بر «اندازه مؤثر کرنل» در محاسبه ابعاد و میدان‌گیری، و (۲) اثر اتساع بر «تعداد پارامتر». مراقب باشید در کدام محاسبه اتساع دخالت می‌کند و در کدام نه.

پرسش ۸

پس‌انتشار در زمان: محاسبه گرادین یک RNN اسکالر

(۹ نمره)

سناریو

یک RNN با حالت پنهان اسکالر در نظر بگیرید:

$$h_t = \tanh(w h_{t-1} + u x_t), \quad w = 0.5, \quad u = 1.0, \quad h_0 = 0.$$

دنباله ورودی $x = [1, 1, 1]$ و زیان نهایی $L = \frac{1}{2}(h_3 - y)^2$ با هدف $y = 0$ است. یادآوری: $\tanh'(a) = 1 - \tanh^2(a)$.

الف) عبور رفت را انجام دهید و h_1, h_2, h_3 و مقدار L را بیابید. (۲ نمره)

ب) فرمول کامل $\frac{\partial L}{\partial w}$ را به‌صورت مجموع بر روی گام‌های زمانی بنویسید (تمایز مشتق «صریح» و «کل» را روشن کنید). (۲ نمره)

ج) مقدار عددی $\frac{\partial L}{\partial w}$ را حساب کنید. (۳ نمره)

توجه

(۱) توضیح دهید چرا یکی از سه جمله مجموع صفر می‌شود. (۲) با نگاه به ضریب هر گام اضافه، به‌طور کمی نشان دهید که این نمونه رفتار «محوشدگی گرادین» را نشان می‌دهد. (۲ نمره)

پرسش ۹

(۹ نمره)

ترنسفورمر: محاسبه توجه و شمارش پارامتر

سناریو

دو توکن با ماتریس‌های زیر داده شده‌اند ($d_k = 2$):

$$Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, \quad V = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

هر ردیف یک بردار توکن است. از توجه نقطه‌ای مقیاس‌شده استفاده کنید ($\sqrt{2} \approx 1.414$, $e^{0.707} \approx 2.028$).

الف) خروجی توجه را بدون ماسک حساب کنید: ماتریس امتیاز، امتیاز مقیاس‌شده، وزن‌های softmax (سطری) و خروجی نهایی. (۳ نمره)

ب) همان محاسبه را با ماسک علی (causal) انجام دهید (توکن اول فقط توکن اول را ببیند). خروجی ردیف اول چگونه تغییر می‌کند؟ (۲ نمره)

ج) برای یک بلوک ترنسفورمر استاندارد با $d_{\text{model}} = 512$ ، $h = 8$ سر و $d_{ff} = 2048$ ، تعداد پارامترهای بخش توجه چندسر و بخش شبکه پیش‌خور (FFN) را (با بایاس) حساب کنید. (۴ نمره)

توجه

در بخش (ج) دو دام هست: (۱) فراموش کردن ماتریس تصویر خروجی W^O ، و (۲) این تصور نادرست که «چون h سر داریم، پارامترها h برابر می‌شوند». نشان دهید چرا مجموع ابعاد سرها برابر d_{model} می‌ماند.

بخش سوم – بررسی و اصلاح کد (۳۰ نمره)

پرسش ۱۰

(۱۰ نمره)

اشکال‌زدایی حلقه آموزش PyTorch

قطعه زیر برای آموزش یک دسته‌بند تصویری با PyTorch نوشته شده اما پنج باگ دارد که آموزش را خراب یا نتایج را نامعتبر می‌کند. هر باگ را بیابید، علتش را توضیح دهید و اصلاح کنید.

```
1 import torch
2 import torch.nn as nn
3 import torch.nn.functional as F
4
5 class Net(nn.Module):
6     def __init__(self):
```

```

7         super().__init__()
8         self.conv = nn.Conv2d(1, 16, 3, padding=1)
9         self.bn    = nn.BatchNorm2d(16)
10        self.drop = nn.Dropout(0.5)
11        self.fc   = nn.Linear(16 * 28 * 28, 10)
12
13        def forward(self, x):
14            x = F.relu(self.bn(self.conv(x)))
15            x = self.drop(x)
16            x = x.view(x.size(0), -1)
17            x = self.fc(x)
18            return F.softmax(x, dim=1)
19
20    model = Net()
21    criterion = nn.CrossEntropyLoss()
22    optimizer = torch.optim.SGD(model.parameters(), lr=0.01)
23
24    for epoch in range(10):
25        for xb, yb in train_loader:
26            logits = model(xb)
27            loss = criterion(logits, yb)
28            loss.backward()
29            optimizer.step()
30            total_loss += loss
31
32        correct = 0
33        for xb, yb in val_loader:
34            preds = model(xb).argmax(dim=1)
35            correct += (preds == yb).sum()
36        print("acc =", correct / len(val_loader.dataset))

```

(۱۰ نمره)

پرسش ۱۱
اشکال زدایی خودتوجهی علی در NumPy

پیاده‌سازی زیر از «خودتوجهی علی» با NumPy چهار باگ دارد. هر باگ را بیابید، توضیح دهید و اصلاح کنید. (راهنما: به محور softmax، پایداری عددی، جهت ضرب ماتریسی، مقیاس‌دهی و نحوه اعمال ماسک دقت کنید.)

```

1 import numpy as np
2
3 def softmax(x):
4     return np.exp(x) / np.sum(np.exp(x))
5
6 def causal_self_attention(X, Wq, Wk, Wv):
7     # X: (T, d_model)
8     Q = X @ Wq                # (T, d_k)
9     K = X @ Wk                # (T, d_k)
10    V = X @ Wv                # (T, d_v)
11    d_k = Q.shape[-1]
12
13    scores = Q @ K             # want (T, T)
14    scores = scores * d_k
15

```

```

16 # causal mask: token i must not attend to j > i
17 mask = np.triu(np.ones_like(scores), k=1)
18 scores = scores * mask
19
20 A = softmax(scores) # attention weights
21 return A @ V

```

(۱۰ نمره)

پرسش ۱۲
اشکال‌زدایی VAE و گام آموزش GAN

بخش ۱ — خودرمزگذار وردشی (۷ نمره) قطعه زیر (PyTorch) سه باگ در ترفند بازپارامتری‌سازی و تابع زیان VAE دارد:

```

1 import torch
2 import torch.nn.functional as F
3
4 def reparameterize(mu, logvar):
5     std = logvar
6     eps = torch.randn_like(std)
7     z = mu + eps * std
8     return z
9
10 def vae_loss(recon_x, x, mu, logvar):
11     recon = F.binary_cross_entropy(recon_x, x, reduction='mean')
12     kld = 0.5 * torch.sum(1 + logvar - mu.pow(2) - logvar.exp())
13     return recon + kld

```

بخش ۲ — گام آموزش GAN (۳ نمره) قطعه زیر یک گام آموزش GAN دارد که دو باگ دارد (به تفکیک گرادین مولد و جهت زیان مولد دقت کنید):

```

1 # D: discriminator, G: generator, criterion = nn.BCELoss()
2 # ones, zeros: target labels ; z: noise batch ; real: real images
3
4 d_optimizer.zero_grad()
5 real_loss = criterion(D(real), ones)
6 fake = G(z)
7 fake_loss = criterion(D(fake), zeros)
8 d_loss = real_loss + fake_loss
9 d_loss.backward()
10 d_optimizer.step()
11
12 g_optimizer.zero_grad()
13 g_loss = criterion(D(fake), zeros)
14 g_loss.backward()
15 g_optimizer.step()

```

موفق باشید.